

Calculs mathématiques : mIoU et Dice

Extrait du cours « Segmentation d'images et données rares »

Dr. Khaoula Ben Ali

1. IoU — Intersection over Union

Mesure le recouvrement entre la zone prédite et la zone réelle d'une classe.

$$IoU = \text{Intersection} / \text{Union}$$

Limite : sévère pour les petits objets — une petite erreur de contour fait chuter fortement le score.

2. mIoU — mean IoU

La moyenne des IoU calculés indépendamment pour chaque classe, puis moyennés sur l'ensemble des classes.

$$mIoU = (1 / C) \times \sum IoU_c \quad (c = 1 \dots C)$$

C'est la métrique de référence en segmentation sémantique. Limite : sensible aux classes rares (une classe quasi absente peut faire chuter la moyenne si elle est mal reconnue).

3. Dice — F1 des pixels

Mesure le recouvrement entre prédiction et vérité terrain, mais pondère différemment de l'IoU : le facteur 2 compense le double comptage de l'intersection (une fois dans chaque terme du dénominateur).

$$Dice = 2 \times \text{Intersection} / (\text{Prédits} + \text{Réels})$$

Plus indulgent que l'IoU pour le même écart de recouvrement. Fortement corrélé à l'IoU.

4. Relation mathématique entre Dice et IoU

Les deux métriques sont liées par une formule de conversion directe :

$$Dice = 2 \times IoU / (1 + IoU)$$

Conséquence pratique : un modèle qui améliore son IoU améliore automatiquement son Dice, et inversement — ce ne sont pas deux informations indépendantes, mais deux façons de lire le même recouvrement.

5. Tableau récapitulatif des métriques

Métrique	Formule	Ce qu'elle mesure
Exactitude par pixel	Pixels bien classés / total des pixels	Proportion de pixels corrects (trompeuse si le fond domine)
IoU	Intersection / Union	Recouvrement prédiction / vérité (sévère pour petits objets)
mIoU	Moyenne des IoU par classe	Métrique de référence en segmentation
Dice (F1 des pixels)	$2 \times \text{Intersection} / (\text{Prédits} + \text{Réels})$	Recouvrement, plus indulgent que l'IoU

6. Fonctions de perte associées (pour l'entraînement)

La métrique Dice a son équivalent en fonction de perte, utilisée pendant l'entraînement (pas seulement en évaluation) :

Dice loss

$$L_Dice = 1 - (2 \times \Sigma(p \cdot g) + \epsilon) / (\Sigma p + \Sigma g + \epsilon)$$

- p = probabilités prédites par le modèle
- g = vérité terrain (ground truth)
- ϵ = terme de lissage, évite la division par zéro quand une classe est absente

Cross-Entropy (pour comparaison)

$$L_CE = -(1/N) \times \Sigma_i \Sigma_c y_{(i,c)} \times \log(p_{(i,c)})$$

Perte combinée (utilisée dans le notebook FoodSeg103)

$$L = 0.7 \times L_CE + 0.3 \times L_Dice$$

L'entropie croisée stabilise l'apprentissage pixel par pixel ; la Dice loss améliore le recouvrement des régions, ce qui aide particulièrement les classes rares ou de petite taille.

7. Point clé à retenir

Exemple du piège de l'exactitude (section 5.2 du cours) : si le fond couvre 80 % d'une image, un modèle qui prédit « fond » partout obtient 80 % d'exactitude par pixel, sans reconnaître un seul aliment. Son mIoU, en revanche, sera très faible — c'est pourquoi on rapporte toujours le mIoU en segmentation, jamais la seule exactitude par pixel.

8. Les trois types de segmentation

La segmentation sémantique est celle qui attribue un label (une classe) à chaque pixel. Elle ne distingue pas les objets individuels d'une même classe — c'est le type utilisé dans FoodSeg103 (masque = un numéro de classe par pixel).

Type	Question posée	Exemple
Sémantique	À quelle classe appartient ce pixel ?	Tous les pixels « tomate » ont la même couleur
D'instance	À quel objet précis appartient ce pixel ?	Chaque tomate a sa propre couleur
Panoptique	Les deux à la fois	Objets comptables séparés + fond (« stuff ») segmenté

Segmentation d'instance : distingue chaque objet individuellement (chaque tomate a son propre identifiant), même si elles partagent la même classe.

Segmentation panoptique : combine les deux — labels de classe partout, ET distinction des objets individuels pour les classes « comptables ».